Base de datos de geoquímica de rocas

Descripción, origen y preparación de la base EarthChem / PetDB usada en el proyecto de estadística y machine learning · octubre de 2026

1. Qué es esta base

La base reúne 159.760 análisis químicos de rocas tomados de muestras recolectadas en todo el mundo. Cada fila corresponde al análisis de una muestra de *roca total*, es decir, de la roca molida y medida en conjunto, no de un mineral en particular. Para cada muestra se informa su composición en elementos mayores (sílice, aluminio, magnesio, calcio, sodio, potasio y otros, expresados como óxidos en porcentaje en peso), en elementos traza (en partes por millón) y en tierras raras, junto con información sobre el tipo de roca, el lugar donde se tomó, el ambiente geológico en que se formó y el artículo científico que publicó el dato.

Predominan las rocas ígneas, y en particular los basaltos (72.307 análisis), seguidos por peridotitas, tefras, harzburgitas, diabasas, lherzolitas, gabros y andesitas. Cerca de 65% de las muestras proviene del fondo oceánico, lo que se explica por el origen de la base: PetDB nació para reunir los datos de las dorsales oceánicas y de las perforaciones de los programas internacionales de exploración del océano (DSDP, ODP e IODP).

2. De dónde salieron los datos

Los datos provienen de **PetDB** (*Petrological Database*), una de las bases que integran **EarthChem**, la infraestructura de datos geoquímicos financiada por la National Science Foundation de Estados Unidos. Hoy PetDB se consulta a través de la *Astromaterials Data Synthesis* (search.astromat.org) y del portal de EarthChem (www.earthchem.org/petdb).

PetDB no genera datos propios: su equipo los transcribe de artículos científicos revisados por pares y los ordena en un formato común. La exportación usada aquí reúne datos de 2.348 artículos publicados entre 1932 y 2025; algo más de la mitad (58%) corresponde a trabajos publicados desde el año 2000. Cada fila conserva la cita completa del artículo de origen y un enlace a la ficha de la muestra en PetDB, de modo que cualquier valor se puede rastrear hasta su publicación.

La descarga se hizo el **13 de octubre de 2026** desde el buscador de PetDB, con un único filtro: material analizado igual a *roca total* (incluyendo el material registrado como *roca total o vidrio sin especificar*). Se pidieron todas las familias de variables disponibles: elementos mayores, trazas, tierras raras, edades, miembros extremos, moda mineral, gases nobles y volátiles. La dirección exacta de la consulta quedó guardada en el repositorio, así que la descarga se puede repetir.

Archivo de la consulta: `data/raw/earthchem_export_oct13_26_142339.txt`

Los datos se distribuyen bajo licencia **Creative Commons Atribución 4.0 (CC BY 4.0)**: pueden usarse, transformarse y redistribuirse libremente siempre que se cite la fuente.

3. Cómo se preparó

La exportación original venía en dos archivos que suman unos 600 MB: uno con los resultados químicos, de 2.318 columnas, y otro con los datos descriptivos de cada muestra (ubicación, ambiente tectónico, textura, alteración, edad). Las columnas son tantas porque cada variable química viene acompañada de tres columnas de texto que indican el método analítico, un comentario

sobre el método y el laboratorio. Esa información es valiosa para un especialista, pero para el análisis estadístico solo agrega ruido.

La preparación consistió en: (a) unir los dos archivos, verificando que las muestras coincidieran fila por fila; (b) quitar las columnas de método, comentario y laboratorio; (c) conservar solo las variables químicas que tienen datos en al menos el 5 % de las muestras, lo que deja 52 variables y descarta, entre otras, las relaciones isotópicas, que aparecen en menos del 2 % de las filas; (d) convertir las coordenadas a grados decimales, con el sur y el oeste en negativo; y (e) dejar vacía, y no en cero, toda celda química sin medición. Además se construyeron cuatro variables nuevas, descritas en la sección siguiente. Todo el proceso está escrito en `scripts/limpiar.py` y se puede volver a ejecutar sobre los archivos originales.

4. Variables

La base final tiene **159.760 filas y 74 columnas**. Las variables cubren todos los tipos que se usan en estadística:

Tipo	Variables	Comentario
Nominales	Sample Type, Sample SubType, Tectonic Setting, Geographic Features, Rock Texture, Geologic Age, Expedition, Citation, Sample Alteration	Categorías sin orden. Por ejemplo, el ambiente tectónico tiene 59 valores y el subtipo de roca 142.
Nominal binaria	Analyzed Material	Solo dos valores: roca total y roca total o vidrio sin especificar.
Ordinales	SiO2 Class, Alteration Grade	Construidas para el proyecto. SiO2 Class clasifica la roca por su contenido de sílice: ultrabásica (menos de 45 %), básica (45–52 %), intermedia (52–63 %) y ácida (63 % o más). Alteration Grade traduce la alteración informada a una escala de 0 (fresca) a 5 (totalmente alterada).
Numéricas discretas	Publication Year, N Analytes	Solo toman valores enteros. El año sale de la cita; N Analytes cuenta cuántas variables químicas se midieron en la muestra (mediana: 9).
Numéricas continuas	52 variables químicas, Latitude, Longitude, elevación mínima y máxima, edad máxima y mínima (Ma)	Óxidos mayores en % en peso (wt%); trazas y tierras raras en partes por millón (ppm).
Identificadores	Sample Name, Sample URL	No se analizan; sirven para rastrear cada muestra.

El diccionario completo, con el tipo de cada columna y el porcentaje de filas con dato, está en el anexo.

5. Requisitos del trabajo

Requisito	Exigido	Base
Filas	al menos 10.000	159.760
Columnas	al menos 30	74
Tipos de variables	nominales, ordinales, discretas y continuas	todos presentes (sección 4)

6. Limitaciones que conviene conocer

No todas las muestras tienen todas las mediciones. Cada artículo midió lo que necesitaba para su investigación, por lo que la base tiene muchos huecos. Solo 46.310 filas (29%) tienen completos

los seis óxidos principales (SiO2, Al2O3, MgO, CaO, Na2O y K2O), y las tierras raras aparecen en una de cada cinco filas. Hay incluso filas sin ninguna variable química, porque en ellas solo se informó la edad o la moda mineral. Una celda vacía significa que el valor no se midió, no que valga cero; conviene filtrar las filas completas para cada análisis en lugar de rellenar los huecos sin criterio.

Falta el TiO2. El óxido de titanio, uno de los elementos mayores más usados para clasificar basaltos, prácticamente no vino en la exportación (cuatro valores en total). Si el análisis lo requiere, habrá que volver a descargarlo desde PetDB.

Unidades y formas distintas para un mismo elemento. Níquel, cobalto, cobre y zinc aparecen tanto en % en peso como en ppm (1 % equivale a 10.000 ppm), y el hierro se informa de cuatro maneras (FeO, Fe2O3, FeOT y Fe2O3T). Antes de comparar hay que llevar todo a una misma unidad.

Sesgos de origen. Los datos reflejan lo que la comunidad científica decidió estudiar y publicar a lo largo de casi un siglo: hay muchos más basaltos de fondo oceánico que rocas continentales, y los métodos de laboratorio cambiaron con el tiempo. El ambiente tectónico más frecuente, *spreading center*, reúne 26.621 muestras, mientras que otros tienen apenas unas decenas; algunas categorías además combinan dos ambientes y conviene agruparlas antes de usarlas como clases en un modelo.

Información descriptiva incompleta. La ubicación está prácticamente siempre, pero la edad geológica figura solo en alrededor del 10 % de las muestras y la alteración en una de cada cinco.

7. Acceso y cita

La base limpia está en el repositorio del proyecto, en `data/earthchem_limpio.csv.gz` (github.com/DalemberV/geoquimica-earthchem-ml). El archivo está comprimido; para abrirlo en Excel hay que descomprimirlo primero (por ejemplo con 7-Zip) e importarlo desde *Datos* > *Desde texto/CSV* con codificación UTF-8 y configuración regional Inglés (Estados Unidos), para que el punto se lea como separador decimal. La página dalemberv.github.io/geoquimica-earthchem-ml muestra un resumen visual de los datos.

Cita sugerida: *Datos descargados de EarthChem PetDB / Astromaterials Data Synthesis (https://search.astromat.org/) el 13 de octubre de 2026, con los parámetros: material analizado = roca total; variables = elementos mayores, trazas, tierras raras, edades, miembros extremos, moda, gases nobles y volátiles. Licencia CC BY 4.0.*

Anexo. Diccionario de variables

Columna	Tipo	% con dato
Sample Name	identificador	99,5
Sample URL	identificador	100,0
Citation	nominal	100,0
Publication Year	discreta	100,0
Analyzed Material	nominal (binaria)	100,0
Sample Type	nominal	100,0
Sample SubType	nominal	100,0
Latitude	continua	100,0
Longitude	continua	100,0

Columna	Tipo	% con dato
Geographic Features	nominal	99,8
Tectonic Setting	nominal	99,8
Rock Texture	nominal	24,9
Sample Alteration	nominal (texto original)	22,1
Elevation Min (m)	continua	53,5
Elevation Max (m)	continua	39,2
Geologic Age	nominal	10,5
Geologic Age Max (Ma)	continua	5,5
Geologic Age Min (Ma)	continua	7,9
Expedition	nominal	99,9
Alteration Grade	ordinal	20,8
SiO2 Class	ordinal	35,7
N Analytes	discreta	100,0
SiO2 (wt%)	continua	35,7
Al2O3 (wt%)	continua	35,9
Fe2O3 (wt%)	continua	14,6
Fe2O3T (wt%)	continua	8,1
FeO (wt%)	continua	13,8
FeOT (wt%)	continua	9,1
MgO (wt%)	continua	35,7
MnO (wt%)	continua	34,5
CaO (wt%)	continua	35,8
Na2O (wt%)	continua	34,5
K2O (wt%)	continua	34,0
P2O5 (wt%)	continua	30,2
Co (wt%)	continua	6,9
Cu (wt%)	continua	7,8
LOI (wt%)	continua	15,6
Ni (wt%)	continua	8,7
Zn (wt%)	continua	8,0
Rb (ppm)	continua	27,7
Sr (ppm)	continua	31,1
Ba (ppm)	continua	25,1
Cs (ppm)	continua	11,2
Pb (ppm)	continua	15,2
Y (ppm)	continua	27,5
Zr (ppm)	continua	28,8
Hf (ppm)	continua	16,8
Nb (ppm)	continua	24,4
Ta (ppm)	continua	14,2
Th (ppm)	continua	18,1

Columna	Tipo	% con dato
U (ppm)	continua	15,9
Ni (ppm)	continua	16,7
Co (ppm)	continua	10,5
V (ppm)	continua	20,8
Cr (ppm)	continua	23,7
Sc (ppm)	continua	18,6
Cu (ppm)	continua	10,3
Ga (ppm)	continua	10,7
Li (ppm)	continua	5,7
Zn (ppm)	continua	12,6
Ce (ppm)	continua	21,8
Dy (ppm)	continua	15,6
Er (ppm)	continua	15,4
Eu (ppm)	continua	19,1
Gd (ppm)	continua	15,6
Ho (ppm)	continua	13,7
La (ppm)	continua	21,6
Lu (ppm)	continua	17,0
Nd (ppm)	continua	20,6
Pr (ppm)	continua	14,5
Sm (ppm)	continua	20,3
Tb (ppm)	continua	16,9
Tm (ppm)	continua	11,2
Yb (ppm)	continua	19,1